

# Probabilidad y Estadística para Inteligencia Artificial

Dr. Ing. Pablo Briff

Laboratorio de Sistemas Embebidos - FIUBA

*pbriff@fi.uba.ar*

8 de Agosto de 2020



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Tabla de Contenidos I

## 1 Enfoque Frecuentista

- Enfoque Frecuentista
- Estimación Bayesiana
- Distribuciones A Priori y A Posteriori
- Cómo Elegir una Distribución A Priori
- Distribución A Priori No-Informativa
- Distribución Beta
- Estimador Puntual Bayesiano
- Máximo a Posteriori

## 2 Ejercicios Práctico-Teóricos

- Ejercicio 1
- Ejercicio 2
- Ejercicio 3

## 3 Bibliografía



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo
- Los datos son generados aleatoriamente, ya sea a través de un proceso simulado o natural



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo
- Los datos son generados aleatoriamente, ya sea a través de un proceso simulado o natural
- Hacemos hipótesis acerca del proceso que genera los datos, por ej Gaussianas i.i.d



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo
- Los datos son generados aleatoriamente, ya sea a través de un proceso simulado o natural
- Hacemos hipótesis acerca del proceso que genera los datos, por ej. Gaussiana i.i.d
- El proceso generador de datos está asociado con algún objeto de interés, por ej. un parámetro, o una distribución



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo
- Los datos son generados aleatoriamente, ya sea a través de un proceso simulado o natural
- Hacemos hipótesis acerca del proceso que genera los datos, por ej. Gaussiana i.i.d
- El proceso generador de datos está asociado con algún objeto de interés, por ej. un parámetro, o una distribución
- Este objeto es desconocido pero constante, y nos interesa encontrarlo



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Enfoque Frecuentista

- Hasta ahora hemos tomado un enfoque frecuentista de la probabilidad y estadística
- En el enfoque frecuentista, hacemos lo siguiente:
- Tomamos datos, a través de un muestreo repetitivo
- Los datos son generados aleatoriamente, ya sea a través de un proceso simulado o natural
- Hacemos hipótesis acerca del proceso que genera los datos, por ej Gaussianas i.i.d
- El proceso generador de datos está asociado con algún objeto de interés, por ej. un parámetro, o una distribución
- Este objeto es desconocido pero constante, y nos interesa encontrarlo
- **Encontramos una estimación de este objeto, o hacemos un test de hipótesis con este objeto**



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- La estimación Bayesiana trata al parámetro, por ej  $\theta$ , como una v.a. que toma valores  $\Theta$



# Estimación Bayesiana

- La estimación Bayesiana trata al parámetro, por ej  $\theta$ , como una v.a. que toma valores  $\Theta$
- La información y creencias acerca de los valores de  $\theta$  sin ninguna medición se resumen en una distribución *a priori*  $\pi(\theta)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- La estimación Bayesiana trata al parámetro, por ej  $\theta$ , como una v.a. que toma valores  $\Theta$
- La información y creencias acerca de los valores de  $\theta$  sin ninguna medición se resumen en una distribución *a priori*  $\pi(\theta)$
- Al observar datos  $X = x$ , se combina la información para obtener la distribución *a posteriori*  $\pi(\theta|x)$



- La estimación Bayesiana trata al parámetro, por ej  $\theta$ , como una v.a. que toma valores  $\Theta$
- La información y creencias acerca de los valores de  $\theta$  sin ninguna medición se resumen en una distribución *a priori*  $\pi(\theta)$
- Al observar datos  $X = x$ , se combina la información para obtener la distribución *a posteriori*  $\pi(\theta|x)$
- Ejemplos de aplicaciones de estimación Bayesiana: filtros de spam, reconocimiento de texto, machine learning, ensayos clínicos, etc



# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:

- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$
- $\pi(\theta|x)$  es la distribución a posteriori



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$
- $\pi(\theta|x)$  es la distribución a posteriori
- $f_X(x|\theta)$  es la verosimilitud



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$
- $\pi(\theta|x)$  es la distribución a posteriori
- $f_X(x|\theta)$  es la verosimilitud
- $\pi(\theta)$  es la distribución a priori



# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$
- $\pi(\theta|x)$  es la distribución a posteriori
- $f_X(x|\theta)$  es la verosimilitud
- $\pi(\theta)$  es la distribución a priori
- La función  $f_X(x)$  no depende de  $\theta$  y es un factor de normalización



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Distribuciones A Priori y A Posteriori

- Por Bayes tenemos:
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Caso continuo:  $f_X(x) = \int f_X(x|\theta)\pi(\theta)d\theta$
- Caso discreto:  $\sum_i f_X(x|\theta_i)\pi(\theta_i)$
- Entonces tenemos:
- $\pi(\theta|x) \propto f_X(x|\theta)\pi(\theta)$
- $\pi(\theta|x)$  es la distribución a posteriori
- $f_X(x|\theta)$  es la verosimilitud
- $\pi(\theta)$  es la distribución a priori
- La función  $f_X(x)$  no depende de  $\theta$  y es un factor de normalización
- Los datos *entran* a través de la verosimilitud



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Ejemplo

- $\pi(\theta)$  es una creencia a priori, y  $\pi(\theta|x)$  es una creencia a posteriori



# Ejemplo

- $\pi(\theta)$  es una creencia a priori, y  $\pi(\theta|x)$  es una creencia a posteriori
- Ejemplo:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Ejemplo

- $\pi(\theta)$  es una creencia a priori, y  $\pi(\theta|x)$  es una creencia a posteriori
- Ejemplo:
- Tengo 3 monedas en el bolsillo: la moneda 1 está *cargada* 3:1 a favor de ceca, la moneda 2 está balanceada, y la moneda 3 está cargada 3:1 a favor de cara



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Ejemplo

- $\pi(\theta)$  es una creencia a priori, y  $\pi(\theta|x)$  es una creencia a posteriori
- Ejemplo:
- Tengo 3 monedas en el bolsillo: la moneda 1 está *cargada* 3:1 a favor de ceca, la moneda 2 está balanceada, y la moneda 3 está cargada 3:1 a favor de cara
- Si saco una moneda al azar y la tiro y me da cara, ¿cuál es la probabilidad de haber elegido la moneda 3?



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes

- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:
- Cómo elegir la distribución a priori, y



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:
- Cómo elegir la distribución a priori, y
- Cómo calcular la densidad a posteriori  $\pi(\theta|x)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:
- Cómo elegir la distribución a priori, y
- Cómo calcular la densidad a posteriori  $\pi(\theta|x)$
- Conviene elegir una distribución a priori con colas poco pronunciadas para no limitar  $\theta$  demasiado



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:
- Cómo elegir la distribución a priori, y
- Cómo calcular la densidad a posteriori  $\pi(\theta|x)$
- Conviene elegir una distribución a priori con colas poco pronunciadas para no limitar  $\theta$  demasiado
- Cuando no se tiene información suficiente sobre  $\theta$ , usaremos distribuciones no informativas



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Cómo Elegir una Distribución A Priori

- Volviendo a la expresión de Bayes
- $\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{f_X(x)}$
- Las preguntas frecuentes en estimación Bayesiana son:
- Cómo elegir la distribución a priori, y
- Cómo calcular la densidad a posteriori  $\pi(\theta|x)$
- Conviene elegir una distribución a priori con colas poco pronunciadas para no limitar  $\theta$  demasiado
- Cuando no se tiene información suficiente sobre  $\theta$ , usaremos distribuciones no informativas
- En general, también conviene – por simplicidad – usar distribuciones conjugadas



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa
- Por ej, una distribución uniforme,  $\pi(\theta) = 1$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa
- Por ej, una distribución uniforme,  $\pi(\theta) = 1$
- La distribución a priori puede no integrar a 1, o inclusive puede no ser integrable



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa
- Por ej, una distribución uniforme,  $\pi(\theta) = 1$
- La distribución a priori puede no integrar a 1, o inclusive puede no ser integrable
- Ejemplo:  $\pi(\theta) = 1$  con  $\theta \in \mathbb{R}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa
- Por ej, una distribución uniforme,  $\pi(\theta) = 1$
- La distribución a priori puede no integrar a 1, o inclusive puede no ser integrable
- Ejemplo:  $\pi(\theta) = 1$  con  $\theta \in \mathbb{R}$
- En este caso  $\int_{-\infty}^{+\infty} \pi(\theta) d\theta = \infty$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución A Priori No-Informativa

- Cuando no disponemos de información acerca del parámetro  $\theta$  elegimos una distribución a priori que no favorezca ningún valor
- Esto es una distribución a priori no informativa
- Por ej, una distribución uniforme,  $\pi(\theta) = 1$
- La distribución a priori puede no integrar a 1, o inclusive puede no ser integrable
- Ejemplo:  $\pi(\theta) = 1$  con  $\theta \in \mathbb{R}$
- En este caso  $\int_{-\infty}^{+\infty} \pi(\theta) d\theta = \infty$
- Sin embargo, la distribución a posteriori aún puede ser que integre a 1 (y esto es lo que importa)



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- La distribución Beta tiene forma de Bernoulli multivariable



# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$
- donde  $K = 1/B(\alpha, \beta)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$
- donde  $K = 1/B(\alpha, \beta)$
- $B(\cdot)$  es la función Beta, dada por:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$
- donde  $K = 1/B(\alpha, \beta)$
- $B(\cdot)$  es la función Beta, dada por:
- $B(\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$
- donde  $K = 1/B(\alpha, \beta)$
- $B(\cdot)$  es la función Beta, dada por:
- $B(\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}$
- $\Gamma(n) = (n-1)!$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- La distribución Beta tiene forma de Bernoulli multivariable
- Si  $X$  es una v.a. con distribución Beta, tiene la siguiente pdf:
- $f_X(x, \alpha, \beta) = K x^{\alpha-1} (1-x)^{\beta-1}$
- donde  $K = 1/B(\alpha, \beta)$
- $B(\cdot)$  es la función Beta, dada por:
- $B(\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}$
- $\Gamma(n) = (n-1)!$
- $\Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx \quad \Re(z) > 0$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- Si  $X \sim B(\alpha, \beta)$ , entonces:



# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$
- $\text{var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$
- $\text{var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- Con la distribución beta, se pueden emular varias distribuciones



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$
- $\text{var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- Con la distribución beta, se pueden emular varias distribuciones
- Uniforme, con  $\alpha = \beta = 1$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$
- $\text{var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- Con la distribución beta, se pueden emular varias distribuciones
- Uniforme, con  $\alpha = \beta = 1$
- Aproximadamente normal, con  $\alpha = \beta = 5$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Beta

- Si  $X \sim B(\alpha, \beta)$ , entonces:
- $E[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Moda}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}$ , para  $\alpha, \beta > 1$
- $\text{var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- Con la distribución beta, se pueden emular varias distribuciones
- Uniforme, con  $\alpha = \beta = 1$
- Aproximadamente normal, con  $\alpha = \beta = 5$
- Exponencial,  $\alpha = 1, \beta = 3$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$
- $\pi(\theta|\mathbf{x}) \propto f_{\mathbf{X}}(\mathbf{x}|\theta)\pi(\theta) \propto \theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}$ , con  $\theta \in (0, 1)$





# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$
- $\pi(\theta|\mathbf{x}) \propto f_{\mathbf{X}}(\mathbf{x}|\theta)\pi(\theta) \propto \theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}$ , con  $\theta \in (0, 1)$
- Esta es una distribución Beta,  $B(\sum_i x_i + a, n - \sum_i x_i + b)$ , entonces



# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$
- $\pi(\theta|\mathbf{x}) \propto f_{\mathbf{X}}(\mathbf{x}|\theta)\pi(\theta) \propto \theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}$ , con  $\theta \in (0, 1)$
- Esta es una distribución Beta,  $B(\sum_i x_i + a, n - \sum_i x_i + b)$ , entonces
- $\pi(\theta|\mathbf{x}) = \frac{\theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}}{B(\sum_i x_i + a, n - \sum_i x_i + b)}$ , con  $\theta \in (0, 1)$



# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$
- $\pi(\theta|\mathbf{x}) \propto f_{\mathbf{X}}(\mathbf{x}|\theta)\pi(\theta) \propto \theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}$ , con  $\theta \in (0, 1)$
- Esta es una distribución Beta,  $B(\sum_i x_i + a, n - \sum_i x_i + b)$ , entonces
- $\pi(\theta|\mathbf{x}) = \frac{\theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}}{B(\sum_i x_i + a, n - \sum_i x_i + b)}$ , con  $\theta \in (0, 1)$
- La ventaja de que sea una distribución conjugada es que la forma matemática se mantiene entre la distribución a priori y a posteriori, facilitando el análisis



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Supongamos una verosimilitud Bernoulli multivariable, es decir
- $f_{\mathbf{X}}(\mathbf{x}|\theta) = \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}$
- Proponemos una distribución a priori Beta,  $\pi(\theta) = B(a, b)$
- $\pi(\theta|\mathbf{x}) \propto f_{\mathbf{X}}(\mathbf{x}|\theta)\pi(\theta) \propto \theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}$ , con  $\theta \in (0, 1)$
- Esta es una distribución Beta,  $B(\sum_i x_i + a, n - \sum_i x_i + b)$ , entonces
- $\pi(\theta|\mathbf{x}) = \frac{\theta^{\sum_i x_i + a - 1} (1 - \theta)^{n - \sum_i x_i + b - 1}}{B(\sum_i x_i + a, n - \sum_i x_i + b)}$ , con  $\theta \in (0, 1)$
- La ventaja de que sea una distribución conjugada es que la forma matemática se mantiene entre la distribución a priori y a posteriori, facilitando el análisis
- Para elegir una distribución a priori, hay que encontrar una distribución Beta que se ajuste a los datos que tenemos



# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:



# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$



**FACULTAD  
DE INGENIERÍA**  
Universidad de Buenos Aires



# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$
- $\text{Moda}[X]$  cualquier valor entre 0 y 1



**FACULTAD  
DE INGENIERÍA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$
- $\text{Moda}[X]$  cualquier valor entre 0 y 1
- $\text{var}[X] = 1/12$



**FACULTAD  
DE INGENIERÍA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$
- $\text{Moda}[X]$  cualquier valor entre 0 y 1
- $\text{var}[X] = 1/12$
- Para la distribución a posteriori, tenemos:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$
- $\text{Moda}[X]$  cualquier valor entre 0 y 1
- $\text{var}[X] = 1/12$
- Para la distribución a posteriori, tenemos:
- $E[X] = \frac{\sum_i x_i + 1}{n + 2}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
  - $E[X] = 1/2$
  - $\text{Moda}[X]$  cualquier valor entre 0 y 1
  - $\text{var}[X] = 1/12$
- Para la distribución a posteriori, tenemos:
  - $E[X] = \frac{\sum_i x_i + 1}{n + 2}$
  - $\text{Moda}[X] = \frac{\sum_i x_i}{n}$ , i.e. estimador de máxima verosimilitud



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Distribución Conjugada

- Si no tenemos información previa sobre  $\theta$  es razonable usar una uniforme cero-uno como distribución a priori, es decir  $\pi(\theta) = B(1, 1)$
- La distribución a posteriori es entonces  $B(\sum_i x_i + 1, n - \sum_i x_i + 1)$
- Para la distribución a priori, tenemos:
- $E[X] = 1/2$
- $\text{Moda}[X]$  cualquier valor entre 0 y 1
- $\text{var}[X] = 1/12$
- Para la distribución a posteriori, tenemos:
- $E[X] = \frac{\sum_i x_i + 1}{n + 2}$
- $\text{Moda}[X] = \frac{\sum_i x_i}{n}$ , i.e. estimador de máxima verosimilitud
- $\text{var}[X] = \frac{(\sum_i x_i + 1)(n - \sum_i x_i + 1)}{(n + 2)^2(n + 3)}$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual



# Estimador Puntual Bayesiano

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual
- Definamos una función de costo  $L(\theta, a)$ , la cual modela la pérdida o costo incurrido al estimar un valor  $a$  del parámetro real  $\theta$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Estimador Puntual Bayesiano

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual
- Definamos una función de costo  $L(\theta, a)$ , la cual modela la pérdida o costo incurrido al estimar un valor  $a$  del parámetro real  $\theta$
- Generalmente nos interesa definir funciones convexas del tipo  $L(\theta, a) = (\theta - a)^2$  o  $L(\theta, a) = |\theta - a|$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Estimador Puntual Bayesiano

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual
- Definamos una función de costo  $L(\theta, a)$ , la cual modela la pérdida o costo incurrido al estimar un valor  $a$  del parámetro real  $\theta$
- Generalmente nos interesa definir funciones convexas del tipo  $L(\theta, a) = (\theta - a)^2$  o  $L(\theta, a) = |\theta - a|$
- Definimos la pérdida a posteriori como:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Estimador Puntual Bayesiano

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual
- Definamos una función de costo  $L(\theta, a)$ , la cual modela la pérdida o costo incurrido al estimar un valor  $a$  del parámetro real  $\theta$
- Generalmente nos interesa definir funciones convexas del tipo  $L(\theta, a) = (\theta - a)^2$  o  $L(\theta, a) = |\theta - a|$
- Definimos la pérdida a posteriori como:
- $h(a) = \int L(\theta, a)\pi(\theta|\mathbf{x})d\theta$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Estimador Puntual Bayesiano

- Ahora veremos el enfoque Bayesiano del problema de estimación puntual
- Definamos una función de costo  $L(\theta, a)$ , la cual modela la pérdida o costo incurrido al estimar un valor  $a$  del parámetro real  $\theta$
- Generalmente nos interesa definir funciones convexas del tipo  $L(\theta, a) = (\theta - a)^2$  o  $L(\theta, a) = |\theta - a|$
- Definimos la pérdida a posteriori como:
- $h(a) = \int L(\theta, a) \pi(\theta | \mathbf{x}) d\theta$
- El estimador de Bayes es aquel que minimiza la pérdida a posteriori



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $$h(a) = \int (a - \theta)^2 \pi(\theta | \mathbf{x}) d\theta$$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- Notemos que  $\int \pi(\theta|\mathbf{x}) d\theta = 1$ , entonces



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- Notemos que  $\int \pi(\theta|\mathbf{x}) d\theta = 1$ , entonces
- $a_{opt} \triangleq E[\theta|\mathbf{x}] = \int \theta \pi(\theta|\mathbf{x}) d\theta$



# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- Notemos que  $\int \pi(\theta|\mathbf{x}) d\theta = 1$ , entonces
- $a_{opt} \triangleq E[\theta|\mathbf{x}] = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- $E[\theta|\mathbf{x}]$  es la *media a posteriori*, la cual minimiza la función de pérdida  $h(a)$



FACULTAD  
DE INGENIERIA  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- Notemos que  $\int \pi(\theta|\mathbf{x}) d\theta = 1$ , entonces
- $a_{opt} \triangleq E[\theta|\mathbf{x}] = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- $E[\theta|\mathbf{x}]$  es la *media a posteriori*, la cual minimiza la función de pérdida  $h(a)$
- Por completitud, definimos la *varianza a posteriori* como



FACULTAD  
DE INGENIERIA  
Universidad de Buenos Aires

# Función de Pérdida Cuadrática

- Si usamos una función de pérdida cuadrática, tenemos:
- $h(a) = \int (a - \theta)^2 \pi(\theta|\mathbf{x}) d\theta$
- Para minimizar  $h(a)$ , derivamos con respecto al parámetro  $a$  e igualamos a cero
- $h'(a) = 0 \iff a \int \pi(\theta|\mathbf{x}) d\theta = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- Notemos que  $\int \pi(\theta|\mathbf{x}) d\theta = 1$ , entonces
- $a_{opt} \triangleq E[\theta|\mathbf{x}] = \int \theta \pi(\theta|\mathbf{x}) d\theta$
- $E[\theta|\mathbf{x}]$  es la *media a posteriori*, la cual minimiza la función de pérdida  $h(a)$
- Por completitud, definimos la *varianza a posteriori* como
- $\text{var}[\theta|\mathbf{x}] = \int (\theta - E[\theta|\mathbf{x}])^2 \pi(\theta|\mathbf{x}) d\theta$



- Si usamos una función de pérdida de valor absoluto, tenemos:



# Función de Pérdida Absoluta

- Si usamos una función de pérdida de valor absoluto, tenemos:
- $$h(a) = \int |a - \theta| \pi(\theta|\mathbf{x}) d\theta$$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Absoluta

- Si usamos una función de pérdida de valor absoluto, tenemos:
- $h(a) = \int |a - \theta| \pi(\theta|\mathbf{x}) d\theta$
- Nuevamente minimizamos  $h(a)$ , y llegamos a



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Función de Pérdida Absoluta

- Si usamos una función de pérdida de valor absoluto, tenemos:
- $h(a) = \int |a - \theta| \pi(\theta|\mathbf{x}) d\theta$
- Nuevamente minimizamos  $h(a)$ , y llegamos a
- $h'(a) = 0 \iff \int_{-\infty}^a \pi(\theta|\mathbf{x}) d\theta = \int_a^{+\infty} \pi(\theta|\mathbf{x}) d\theta$



# Función de Pérdida Absoluta

- Si usamos una función de pérdida de valor absoluto, tenemos:
- $h(a) = \int |a - \theta| \pi(\theta|\mathbf{x}) d\theta$
- Nuevamente minimizamos  $h(a)$ , y llegamos a
- $h'(a) = 0 \iff \int_{-\infty}^a \pi(\theta|\mathbf{x}) d\theta = \int_a^{+\infty} \pi(\theta|\mathbf{x}) d\theta$
- La igualdad anterior se cumple con  $a$  tal que parte la distribución  $\pi(\theta|\mathbf{x})$  en dos partes iguales de área  $1/2$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Función de Pérdida Absoluta

- Si usamos una función de pérdida de valor absoluto, tenemos:
- $h(a) = \int |a - \theta| \pi(\theta|\mathbf{x}) d\theta$
- Nuevamente minimizamos  $h(a)$ , y llegamos a
- $h'(a) = 0 \iff \int_{-\infty}^a \pi(\theta|\mathbf{x}) d\theta = \int_a^{+\infty} \pi(\theta|\mathbf{x}) d\theta$
- La igualdad anterior se cumple con  $a$  tal que parte la distribución  $\pi(\theta|\mathbf{x})$  en dos partes iguales de área  $1/2$
- Es decir,  $a_{opt} = \text{Med}[\theta|\mathbf{x}]$  es la *mediana a posteriori*



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:



# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$
- $\hat{\theta}_{ML}$  es un estimador de un único punto



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$
- $\hat{\theta}_{ML}$  es un estimador de un único punto
- Ahora buscamos el estimador de *máximo a posteriori* (MAP) como:



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$
- $\hat{\theta}_{ML}$  es un estimador de un único punto
- Ahora buscamos el estimador de *máximo a posteriori* (MAP) como:
- $\hat{\theta}_{MAP} = \arg \max_{\theta} \pi(\theta|x)$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$
- $\hat{\theta}_{ML}$  es un estimador de un único punto
- Ahora buscamos el estimador de *máximo a posteriori* (MAP) como:
- $\hat{\theta}_{MAP} = \arg \max_{\theta} \pi(\theta|x)$
- A diferencia de ML, en MAP nos valemos de  $\pi(\theta|x)$  para promediar las incertidumbres de  $\theta$



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Máximo a Posteriori

- Recordemos que el estimador de máxima verosimilitud (ML) se encontraba como:
- $\hat{\theta}_{ML} = \arg \max_{\theta} f_X(x|\theta)$
- $\hat{\theta}_{ML}$  es un estimador de un único punto
- Ahora buscamos el estimador de *máximo a posteriori* (MAP) como:
- $\hat{\theta}_{MAP} = \arg \max_{\theta} \pi(\theta|x)$
- A diferencia de ML, en MAP nos valemos de  $\pi(\theta|x)$  para promediar las incertidumbres de  $\theta$
- El estimador MAP es la moda de la distribución a posteriori



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires

# Ejercicio 1

- Estamos interesados en estimar la tasa de mortalidad real  $\theta$  en un hospital  $H$  que está probando un nuevo tratamiento. El promedio de decesos en el país es 10 %, y la tasa de mortalidad varía entre hospitales entre el 3 y 20 %. El hospital  $H$  no tiene decesos en las primeras 10 operaciones. Calcular la media a posteriori  $E[\theta|\mathbf{x}]$ . (Pista: usar como distribución a priori una Beta  $B(3, 27)$ .)



# Ejercicio 2

- a) Encontrar el estimador MAP de  $\theta$  cuando la muestra  $x$ , dado  $\theta$ , tiene una distribución  $X \sim \mathcal{N}(\theta, \sigma_X^2)$  y la distribución a priori de  $\theta$  es  $\mathcal{N}(\theta_0, \sigma_\theta^2)$
- b) Simular el estimador MAP para diversos valores de  $\sigma_X^2$  y  $\sigma_\theta^2$  y sacar conclusiones en los extremos de los valores de las varianzas



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires


# Ejercicio 3

- a) Sean  $X_1, X_2, \dots, X_n \sim \mathcal{N}(\mu, 1)$ . Asumamos una distribución a priori de  $\mu \sim \mathcal{N}(0, \tau^{-2})$ , para  $\tau$  conocido.
- b) Demostrar que la media a posteriori es igual a la mediana a posteriori y ambas son iguales a  $\hat{\mu} = \sum_i x_i / (n + \tau^2)$ .  
(Pista: usar el desarrollo demostrado en [http://www.ams.sunysb.edu/~zhu/ams570/Bayesian\\_Normal.pdf](http://www.ams.sunysb.edu/~zhu/ams570/Bayesian_Normal.pdf))




# Bibliografía I

 E. Alpaydin, *Introduction to machine learning*.  
MIT press, 2020.

 S. M. Kay, *Fundamentals of statistical signal processing*.  
Prentice Hall PTR, 1993.

 “MIT, Statistics for Applications, Bayesian Statistics.”  
[https://ocw.mit.edu/courses/mathematics/  
18-650-statistics-for-applications-fall-2016/  
lecture-slides/MIT18\\_650F16\\_Bayesian\\_Statistics.pdf](https://ocw.mit.edu/courses/mathematics/18-650-statistics-for-applications-fall-2016/lecture-slides/MIT18_650F16_Bayesian_Statistics.pdf).  
Accessed: 2020-05-15.

 “Cambridge, Statistical Department, Bayesian Statistics.”  
[http://www.statslab.cam.ac.uk/Dept/People/djsteaching/  
S1B-17-06-bayesian.pdf](http://www.statslab.cam.ac.uk/Dept/People/djsteaching/S1B-17-06-bayesian.pdf).  
Accessed: 2020-05-15.



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires



“MIT, Brain and Cognitive Sciences, Bayesian Statistics.” [https://ocw.mit.edu/courses/brain-and-cognitive-sciences/9-07-statistics-for-brain-and-cognitive-science-fall-2016/lecture-notes/MIT9\\_07F16\\_lec10.1.pdf](https://ocw.mit.edu/courses/brain-and-cognitive-sciences/9-07-statistics-for-brain-and-cognitive-science-fall-2016/lecture-notes/MIT9_07F16_lec10.1.pdf).

Accessed: 2020-05-15.



**FACULTAD  
DE INGENIERIA**  
Universidad de Buenos Aires